SAFETY 4.0 · GÜNCEL KONULAR PROJESİ · HAFTA 7

AI Safety Challenge

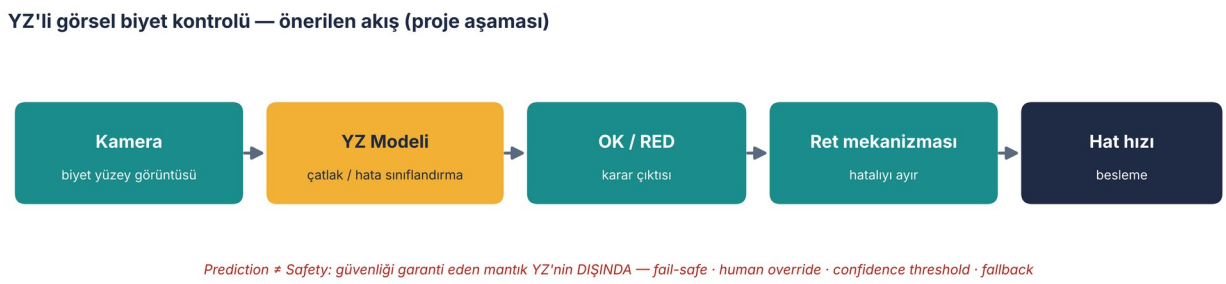
CEOTHERM Homojenizasyon Tesisi

Föy	Çıktı	Makine
Lab 7 · AI Safety Challenge	AI Fail-Safe Decision → EP 03 + EP 15	Fırın + soğutma kabini + biyet transfer arabası

Kavram — Prediction ≠ Safety: Yapay zeka bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: Makineye YZ'li görsel biyet kontrolü (çatlak / yüzey hatası sınıflandırması) eklenmesi planlanıyor. Proje aşaması değerlendirmesi yapılmaktadır; sistem henüz kurulmadı.

Önerilen akış



YZ modeli yalnızca "bu biyet OK mu, RED mi" kararını üretir. Hattı durdurma, parça ayırma ve insana sorma mantığı modelin dışında, klasik kontrol katmanında tanımlanır.

Görev – Üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: kusurlu parçaya OK verdi. Sistem ne yapmalı?

Güvenli davranış: Tek bir YZ kararına üretim güvenini bağlamamak. Kritik kararda ikinci bir bağımsız kontrol olmalı:

- **İkinci kontrol:** Belirli aralıklarla veya riskli partilerde insan/örnekleme kontrolü (human override).
- **İzleme (monitoring):** Modelin OK/RED oranı normalden saparsa alarm. Sürekli "hepsi OK" diyorsa şüphelen.
- **Kavram:** Burada YZ hata yapabilir kabulüyle tasarlanır; güvenlik modelin doğruluğuna değil, dışındaki kontrol katmanına dayanır.

Not: Bu bir kalite kontrol fonksiyonu, emniyet fonksiyonu değil. Yanlış OK ürün kalitesini etkiler; makinenin emniyet katmanını (yakma, kapı, araba) değiştirmez. İkisi karıştırılmamalı.

2. Girdi manipüle edildi: kamera verisi bozuk / sahte. Nasıl fark edilir?

- **Nasıl fark edilir:** Girdi geçerlilik kontrolü — görüntü çözünürlüğü, parlaklık, kare hızı beklenen aralıkta mı? Kamera canlı mı yoksa donmuş/tekrar eden kare mi? Zaman damgası tutarlı mı?

- **Şüpheli girdide ne yapılır:** Model karar üretmeye zorlanmaz. Şüpheli girdi RED'e değil, "karar verilemedi" durumuna gider ve fallback devreye girer (parça insana yönlendirilir veya hat yavaşlar/durur).
- **Kavram:** fail-safe — belirsizlikte sistem tehlikeli değil, güvenli tarafa düşer. Bozuk girdiye "OK" demek en kötü sonuçtur, bundan kaçınılır.

3. Confidence düştü: model "emin değilim" diyor. Eşik ne olmalı?

- **Confidence threshold:** Modelin güven skoru için bir eşik belirlenir. Eşiğin altındaki kararlar geçerli sayılmaz.
- **Altında ne olur:** Otomatik OK verilmez. Parça fallback'e gider: ya insana sorulur (human override) ya da güvenli tarafta RED/ayır olarak işlenir ve kontrole alınır.
- **Eşik nasıl seçilir:** Kaçan kusurlu parçanın maliyeti ile gereksiz RED'in maliyeti dengelenir. Emniyet değil kalite söz konusu olduğu için eşik üretim toleransına göre ayarlanır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış	Hangi kavram
Model yanlış sınıflandırdı	Tek karara güvenme; örnekleme/insan kontrolü + oran izleme ile yakala	human override + monitoring
Girdi manipüle edildi	Girdi geçerlilik kontrolü; şüpheli girdide karar üretme, güvenli tarafa düş	fail-safe
Confidence düştü	Güven eşiğinin altında otomatik karar yok; insana sor veya ayır	confidence threshold + fallback

Ana fikir

Üç durumda da çözüm modeli daha iyi eğitmek değil. Model her zaman hata yapabilir, kandırılabilir, emin olmayabilir. Güvenli davranış modelin dışındaki mantıkla garanti edilir: belirsizlikte sistem güvenli tarafa düşer, kritik kararda insan vardır, anormallik izlenir. Bu makinede YZ yalnızca kalite kararına yardım eder; insanı koruyan emniyet katmanı (Hafta 1) YZ'den tamamen ayrı ve bağımsız kalır.

Eğitim çalışmasıdır. YZ sistemi henüz kurulmadı; değerlendirme proje aşamasındadır.